

УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



SEMINARSKI RAD II

**Uticaj kvaliteta i predobrade slika na performanse modela
za klasifikaciju tumora mozga**

Studijski program: Veštačka inteligencija i mašinsko učenje

Predmet: Prikupljanje i predobrada podataka za mašinsko učenje

Mentor:

prof. dr Aleksandar Stanimirović

Student:

Aleksa Cekić, br. ind. 2117

Niš, 2026.

Table of Contents

1. UVOD	4
2. MEDICINSKE SLIKE KAO ULAZNI PODACI	4
2.1 MRI snimak u kontekstu računarske vizije	5
2.2 Visoka dimenzionalnost i ograničenost skupova	5
2.3 Varijabilnost između modaliteta i protokola	5
3. KVALITET MRI SLIKA I IZVORI DEGRADACIJE	6
3.1 Rezolucija i prostorna informacija	6
3.2 Kontrast i osvetljenje	6
3.3 Šum i izobličenja	7
3.4 Artefakti akvizicije i kompresije	7
3.5 Duplikati i bliske varijante	8
4. TEHNIKE PREDOBRADE SLIKA	8
4.1 Otkrivanje problematičnih primera i čišćenje skupa	8
4.2 Resize i geometrijska normalizacija	8
4.3 Normalizacija intenziteta	9
4.4 Filtriranje šuma i poboljšanje kontrasta	9
5. DATA AUGMENTACIJA	10
5.1 Logika augmentacije i njena uloga	10
5.2 Geometrijske transformacije	11
5.3 Fotometrijske transformacije	11
5.4 Napredne tehnike augmentacije	12
5.5 Granice augmentacije	12
6. SPECIFIČNOSTI PREDOBRADE MEDICINSKIH SLIKA	12
6.1 Skull stripping i izrezivanje regiona od interesa	13
6.2 Bias field korekcija	13
6.3 Registracija i prostorna usklađenost	14
6.4 Strategije za rad sa malim skupovima	14
7. CNN ARHITEKTURE I OSETLJIVOST NA PREDOBRADU	15
7.1 Šta CNN “vidi” i zašto je predobrada bitna	15
7.2 Transfer learning i sukob distribucija	15
7.3 Batch normalization i njen odnos sa ulaznom normalizacijom	16
7.4 Osetljivost arhitekture na ulazne uslove	16
8. UTICAJ PREDOBRADE NA PERFORMANSE KLASIFIKACIJE	17
8.1 Generalizacija i overfitting na malim skupovima	17
8.2 Nebalansiranost klasa	17
8.3 Stabilnost obuke i konvergencija	18
8.4 Pouzdanost u kliničkom kontekstu	18
8.5 Sažeti pogled na vezu predobrade i performansi	19
9. PREPORUKE I SMERNICE	19
9.1 Krenuti od kvaliteta ulaza, a ne od arhitekture	19
9.2 Birati augmentaciju prema vrsti varijabilnosti	19
9.3 Porediti predobrade a ne samo arhitekture	20

9.4 Predobradu ocenjivati preko posledice po model	20
9.5 Voditi računa o doslednosti između faza	21
10. ZAKLJUČAK	21
11. LITERATURA	23

1. UVOD

Magnetna rezonanca (engl. Magnetic Resonance Imaging, MRI) već decenijama predstavlja jedan od osnovnih alata u dijagnostici tumora mozga. Snimak koji radiolog dobije nije samo slika u uobičajenom smislu, već zapis fizičkog procesa interakcije između tkiva i magnetnog polja. Iz takvog zapisa potrebno je proceniti da li tumor postoji, kog je tipa i gde se tačno nalazi. Zadatak je ozbiljan, a odluka često ne trpi odlaganje.

Razvoj dubokih konvolucionih mreža (engl. Convolutional Neural Networks, CNN) otvorio je mogućnost da se deo tog posla automatizuje. Model se obučava nad skupom anotiranih snimaka i potom procenjuje nove slučajeve. Na prvi pogled, problem deluje kao standardni zadatak klasifikacije slika. U praksi se ispostavlja da medicinske slike imaju niz specifičnosti koje obična predstava o “slici kao ulazu” ne hvata u dovoljnoj meri.

MRI snimak nije nastao u kontrolisanim uslovima fotografskog studija. Njegov izgled zavisi od uređaja na kome je napravljen, parametara akvizicije, položaja pacijenta, prisustva pokreta tokom snimanja i niza drugih faktora. Dva snimka istog tipa tumora, načinjena na različitim aparatima, mogu se po izgledu razlikovati više nego dva snimka različitih klasa sa istog uređaja. Ako se ova varijabilnost ne uzme u obzir, model lako nauči da prepozna skener umesto bolesti.

Tema ovog rada je uticaj kvaliteta i tehnika predobrade slika na performanse modela za klasifikaciju tumora mozga. Težište je na teorijskom delu. Cilj nije da se ovde porede konkretni eksperimenti, već da se objasni zbog čega kvalitet ulaznih snimaka, izbor predobrade i način na koji se slika prevodi u oblik pogodan za mrežu menjaju ponašanje klasifikatora.

Rad je organizovan tako da se najpre razmatra priroda medicinskih slika i izvori njihove varijabilnosti, zatim problemi kvaliteta, potom tehnike predobrade i augmentacije, posle toga odnos predobrade prema CNN arhitekturama, pregled uticaja na performanse klasifikacije, i na kraju zaključak. Praktični deo rada, sa konkretnim skupom MRI snimaka i merenjem performansi, ostavljen je za narednu fazu.

2. MEDICINSKE SLIKE KAO ULAZNI PODACI

Slika se u računarskoj viziji obično posmatra kao matrica piksela sa pridruženim vrednostima intenziteta. Takvo gledanje je tačno, ali za medicinske snimke nije dovoljno. Iza svake MRI slike stoji fizički protokol akvizicije, izbor parametara skenera i niz odluka koje radiolog donosi pre nego što dobije konačan snimak. Zato je vredno najpre razumeti šta tačno čini ovaj tip ulaza posebnim.

2.1 MRI snimak u kontekstu računarske vizije

Klasična slika dobijena digitalnim fotoaparatom nastaje u uslovima koji su, uz izuzetke, relativno standardizovani: postoji izvor svetlosti, optički sistem i senzor koji beleži intenzitet u tri kanala boje. MRI snimak nastaje sasvim drugačije. Tkivo se izlaže magnetnom polju i radiofrekventnim impulsima, a signal koji se beleži zavisi od fizičkih osobina samih molekula vode u tkivu. Posledica je da intenzitet piksela na MRI slici nema apsolutno značenje koje bi važilo svuda, već zavisi od toga kako je snimak napravljen.

To je važna razlika u odnosu na standardne zadatke računarske vizije. Kada CNN model klasifikuje fotografije mačaka i pasa, može se osloniti na to da je crna boja crna, a bela bela, bez obzira na to ko je sliku napravio. Kod MRI snimaka takva pretpostavka ne važi. Isto tkivo na različitim uređajima može da ima različitu vrednost intenziteta, a isti uređaj može da daje različite slike u zavisnosti od izbora protokola snimanja.

Zbog toga se medicinska slika ne može posmatrati izolovano od konteksta u kome je nastala. Kvalitet zapisa zavisi od uređaja, parametara akvizicije, kooperativnosti pacijenta i još niza faktora. Sve to dolazi u model kao deo ulaza, bilo da to želimo ili ne.

2.2 Visoka dimenzionalnost i ograničenost skupova

Druga važna osobina medicinskih slika tiče se same količine podataka. Tipična MRI slika ima rezoluciju od nekoliko stotina piksela po stranici, što znači da svaki snimak nosi desetine ili stotine hiljada vrednosti intenziteta. Ako se tome doda i činjenica da se često radi sa više preseka istog mozga, dimenzionalnost postaje veoma velika već za pojedinačan slučaj.

Suprotno tome stoji broj dostupnih primera. Anotiranje medicinskih slika zahteva stručnjaka koji će potvrditi dijagnozu, što je skupo i sporo. Javno dostupni skupovi za klasifikaciju tumora mozga obično sadrže nekoliko hiljada slika, što je daleko ispod onoga što je uobičajeno u opštim zadacima računarske vizije, gde se rade milioni primera. Otuda se javlja klasičan disbalans: prostor obeležja je ogroman, a uzorak je relativno mali.

Posledica takvog odnosa je da modeli postaju osetljivi na svaku sistematsku razliku u podacima. Ako su svi snimci jedne klase napravljeni na istom uređaju, mreža može da nauči karakteristike tog uređaja umesto karakteristika bolesti. Ovaj problem nije teorijski. U literaturi je dobro poznato da modeli obučeni na jednoj bolnici često slabije rade kada se primene na snimcima iz druge ustanove.

2.3 Varijabilnost između modaliteta i protokola

MRI nije jedinstvena tehnika. Različiti protokoli snimanja, poznati kao modaliteti, naglašavaju različite osobine tkiva. T1-ponderisani snimci ističu razlike u sastavu masnog tkiva i obično se koriste za prikaz anatomije. T2-ponderisani snimci

bolje prikazuju tečnosti i edem, što je posebno važno kod tumora. FLAIR sekvence potiskuju signal cerebrospinalne tečnosti i koriste se za uočavanje suptilnijih lezija.

Ako skup podataka sadrži snimke različitih modaliteta, model mora ili da nauči da ih razlikuje i obrađuje na različite načine, ili da se osloni na predobradu koja će ih dovesti u uporedivo stanje. Treća opcija, koja se često sreće u praksi, jeste da se zadatak ograniči na jedan modalitet. Svaka od ovih odluka ima svoje posledice po performanse i moraju se doneti pre nego što se uopšte krene sa obukom modela.

Već iz ovog kratkog pregleda vidi se zašto medicinska slika zahteva posebnu pažnju. Ono što se na prvi pogled čini kao homogen ulaz, u stvari je heterogen skup zapisa nastalih pod različitim uslovima, koje treba metodološki uskladiti pre nego što se uopšte počne razgovor o algoritmima.

3. KVALITET MRI SLIKA I IZVORI DEGRADACIJE

Pitanje kvaliteta slike u medicinskom kontekstu nije isto što i kod opštih fotografija. Kod MRI snimaka ne radi se o estetskim kategorijama poput jasnoće, oštrote ili lepote prikaza, već o tome koliko zapis verno prenosi informaciju o stanju tkiva. Slika može biti vizuelno prijatna, a ipak loše pogodna za automatsku obradu, i obrnuto.

3.1 Rezolucija i prostorna informacija

Rezolucija MRI snimka određuje koliko sitnih detalja se može razlikovati u tkivu. Veća rezolucija znači više piksela po jedinici prostora i potencijalno bolju mogućnost da se uoče male lezije ili rane promene. Na prvi pogled deluje da uvek treba težiti što višoj rezoluciji, ali stvar nije tako jednostavna.

Povećanje rezolucije produžava vreme snimanja i povećava šanse za pojavu artefakata pokreta, jer pacijent duže mora da miruje. Pored toga, snimci visoke rezolucije zauzimaju više prostora i zahtevaju više memorije pri obuci modela. U praksi se zato bira kompromisna rezolucija koja omogućava klinički prihvatljiv prikaz, ali ne opterećuje sistem više nego što je potrebno.

Kada slike u skupu podataka imaju različite rezolucije, javlja se dodatni problem. Mreža očekuje ulaz fiksne veličine, pa se snimci moraju dovesti na zajedničku dimenziju. Ako se to radi naglim smanjivanjem, deo prostorne informacije nestaje, a fini detalji koji bi mogli biti dijagnostički važni se gube. Otuda izbor ciljane rezolucije postaje odluka koja direktno utiče na to šta će model uopšte moći da vidi.

3.2 Kontrast i osvetljenje

Kod klasičnih fotografija pojam kontrasta vezan je za razliku između svetlih i tamnih delova slike. Kod MRI snimaka kontrast nosi mnogo specifičnije značenje: on ukazuje na razliku u signalu između različitih tipova tkiva. Tumor i okolno zdravo tkivo razlikuju se upravo po tome kako reaguju na primenjeno magnetno polje, a ta razlika se na slici manifestuje kao razlika u intenzitetu.

Problem nastaje kada kontrast nije dosledan kroz ceo skup podataka. Snimci sa različitih uređaja, ili čak isti uređaj sa različitim parametrima, mogu prikazivati istu vrstu tkiva sa приметно različitim nivoima intenziteta. Ako mreža uči iz takvog skupa, postoji opasnost da deo svog kapaciteta troši na kompenzovanje razlika u kontrastu umesto na učenje pravih obrazaca bolesti.

Slično važi i za opštu osvetljenost slike. Iako se kod MRI ne radi o klasičnoj svetlosti, pojam srednje vrednosti intenziteta u snimku ima sličnu ulogu. Kada se ta srednja vrednost značajno menja od slike do slike, model mora ili da se nosi sa tim sam, ili da dobije unapred normalizovan ulaz.

3.3 Šum i izobličenja

Šum je možda najpoznatiji oblik degradacije slike. U opštoj računarskoj viziji često se govori o Gausovom šumu (engl. Gaussian noise) i šumu tipa “so i biber” (engl. salt-and-pepper noise), koji se modeliraju kao slučajne perturbacije vrednosti piksela. U MRI kontekstu šum ima i svoju specifičnu komponentu, poznatu kao Rician šum, koja proističe iz prirode samog procesa magnetne rezonance.

Bez obzira na konkretan tip, šum smanjuje odnos signala i pozadine. Kod tumora to može značiti da fine ivice lezije postaju nejasnije, a manje strukture teže uočljive. Kratki snimci, sa kraćim vremenom akvizicije, obično imaju više šuma, pa se i tu javlja kompromis između brzine snimanja i kvaliteta zapisa.

Drugi važan oblik degradacije je zamućenje (engl. blur). Ono može nastati zbog pokreta pacijenta, nesavršenosti optike kod nekih modaliteta ili tehničkih ograničenja samog uređaja. Zamućenje deluje na sliku tako što slabi prelaze između različitih struktura, što kod tumora može značiti gubitak upravo onih ivica koje su bitne za prepoznavanje.

3.4 Artefakti akvizicije i kompresije

Pored opšteg šuma i zamućenja, MRI snimci često nose i specifičnije artefakte. Među njima su artefakti pokreta, koji nastaju kada se pacijent pomeri tokom snimanja, i bias field, sistematska neuniformnost intenziteta u kojoj isti tip tkiva izgleda svetlije u jednom delu slike, a tamnije u drugom. Ovi artefakti ne deluju kao slučajan šum, već imaju strukturu, što ih čini posebno problematičnim.

Mreža, naime, lakše uči obrasce sa strukturom nego potpuno slučajne perturbacije. Ako određeni artefakt sistematski prati jednu klasu tumora, model može da nauči upravo taj artefakt umesto stvarne karakteristike bolesti. Posledica je dobra tačnost na trening skupu i loša generalizacija na nove podatke.

Treba pomenuti i artefakte kompresije. Iako se medicinski snimci u kliničkim sistemima čuvaju u formatima sa malim ili nikakvim gubitkom, javno dostupni skupovi za istraživanje često sadrže slike sačuvane u JPEG formatu, koji unosi

karakteristične blokovske artefakte. Takvi artefakti menjaju lokalnu teksturu slike i mogu uticati na to kako mreža uči ivice i prelaze.

3.5 Duplikati i bliske varijante

Konačno, kvalitet skupa nije samo pitanje pojedinačnih slika. Skup u celini može imati problema čak i ako su pojedinačni snimci besprekorni. Jedan od takvih problema su duplikati i bliske varijante: slike koje su gotovo identične, bilo zato što su kopije istog snimka, bilo zato što potiču od različitih preseka istog pacijenta.

Ako se takve slike nađu i u trening i u test skupu, evaluacija modela postaje nepouzdana. Mreža ne pokazuje koliko je dobro generalizovala, već koliko je dobro zapamtila. Otuda kvalitet skupa zahteva ne samo kontrolu pojedinačnih primera, već i pažljivu organizaciju podele podataka, posebno kada više snimaka može poticati od istog pacijenta.

4. TEHNIKE PREDOBRADE SLIKA

Predobrada nije jedan korak već niz odluka. Cilj je da se sirovi MRI snimak prevede u oblik pogodan za mrežu, pri čemu se uklanja što više nepoželjne varijabilnosti, a čuva ono što nosi dijagnostički signal. Izbor konkretnih tehnika zavisi od skupa podataka, modela i prirode samog problema, pa unapred propisanog recepta nema.

4.1 Otkrivanje problematičnih primera i čišćenje skupa

Pre nego što se uopšte krene sa transformacijama nad slikama, vredi razumeti šta je u skupu zaista problem. Slično kao kod tabelarnih podataka, prvo se traže primeri koji odstupaju od ostatka korpusa: prazni ili gotovo prazni snimci, slike pogrešne dimenzije, snimci sa očiglednim greškama u označavanju klase ili duplikati nastali pri prikupljanju podataka.

Kod medicinskih slika postoji još jedan oblik problema koji se ne vidi odmah. Snimak može biti tehnički ispravan, ali sadržajno neupotrebljiv: na primer, slika koja prikazuje samo deo glave, snimak sa preteranim artefaktom pokreta, ili slika gde je oblast od interesa van vidnog polja. Takvi primeri ne odbacuju se zbog tehničkog kvaliteta, već zato što njihova informaciona vrednost za zadatak nije dovoljna.

Čišćenje skupa nije izolovan zahvat. Uvek se postavlja pitanje da li problematičan primer treba ukloniti, ispraviti ili samo drugačije označiti. Odluka zavisi od konteksta: prazna slika je gotovo uvek beskorisna, ali snimak sa blagim artefaktom može biti vredan zadržavanja, jer realan klinički sistem ionako mora da radi i sa nesavršenim ulazima.

4.2 Resize i geometrijska normalizacija

Konvolucione mreže u svojoj najčešćoj formi očekuju ulaz fiksne dimenzije. Ako slike u skupu imaju različite veličine, prva odluka u predobradi tiče se kako ih

dovesti na zajedničku dimenziju. Najjednostavnije rešenje je promena veličine (engl. *resize*), koja interpolira piksele tako da slika dobije ciljnu rezoluciju.

Promena veličine, međutim, ima svoje cene. Smanjivanje slike znači gubitak detalja, dok povećavanje, sa druge strane, ne dodaje novu informaciju, već samo interpolira postojeću. Pored toga, ako se slike različitih proporcija svode na istu kvadratnu rezoluciju, javlja se izobličenje koje menja oblik anatomskih struktura. Alternativa je izrezivanje (engl. *crop*), gde se uzima samo deo slike koji odgovara ciljnoj dimenziji, ili dopunjavanje ivica (engl. *padding*) prazninom da bi se očuvale proporcije.

Kod MRI snimaka mozga često se koristi i posebniji postupak, poznat kao izrezivanje regiona od interesa. Ideja je da se sa slike ukloni okolna pozadina, pa i deo lobanje, kako bi mreža svoju pažnju usmerila na samo tkivo mozga. Ovaj postupak može smanjiti uticaj nepotrebnih varijacija u pozadini i poboljšati performanse, ali zahteva ili automatsku segmentaciju ili pažljivo ručno označavanje.

4.3 Normalizacija intenziteta

Kao što je već pomenuto, intenzitet piksela na MRI slici nema apsolutno značenje. Iz toga sledi da slike pre obuke moraju biti dovedene u uporedivo stanje. Najjednostavniji oblik normalizacije je skaliranje vrednosti piksela u opseg između nule i jedinice, što se postiže deljenjem maksimalnom mogućom vrednošću intenziteta.

Sofisticiraniji pristup je standardizacija (engl. *Z-score normalization*), gde se od svake vrednosti piksela oduzima srednja vrednost slike, a rezultat deli standardnom devijacijom. Time slika dobija srednju vrednost nula i jediničnu varijansu. Ovaj postupak je posebno koristan kod metoda koje se oslanjaju na gradijente, jer ujednačava skalu ulaznih obeležja i ubrzava konvergenciju.

U medicinskom kontekstu često se sreće još jedan oblik normalizacije, poznat kao *histogram matching*. Ideja je da se raspodela intenziteta sa jedne slike preslikava na referentnu raspodelu, čime se delimično kompenzuju razlike između uređaja i protokola. Iako ne rešava sve probleme varijabilnosti, ovaj postupak može značajno smanjiti razlike u kontrastu između snimaka iz različitih izvora.

Izbor konkretne metode normalizacije nije neutralan. Različite metode menjaju različite aspekte slike, pa se moraju procenjivati u odnosu na kasnije faze obrade. Ono što dobro radi sa jednom arhitekturom mreže ne mora podjednako dobro raditi sa drugom.

4.4 Filtriranje šuma i poboljšanje kontrasta

Kada se utvrdi da slike u skupu sadrže značajan šum, sledeći korak može biti njegovo filtriranje. Klasične tehnike obuhvataju Gausov filter, koji izgladuje sliku zamenom svake vrednosti piksela ponderisanim prosekom susednih piksela, i medijan filter, koji je posebno otporan na šum tipa “so i biber”. Za naprednije slučajeve koristi se i

non-local means filter, koji koristi sličnost između udaljenih delova slike da bi razlikovao šum od strukture.

Filtriranje šuma uvek nosi sa sobom rizik gubitka korisne informacije. Previše agresivan filter izgadiće ne samo šum, već i fine detalje koji mogu biti dijagnostički važni. Zbog toga se izbor i jačina filtera ne podešavaju na osnovu opšteg utiska o izgledu slike, već u odnosu na to kako se menja ponašanje modela koji se obučava na takvim slikama.

Suprotnu ulogu ima poboljšanje kontrasta. Kada slike imaju slab kontrast, mogu se primeniti tehnike koje šire raspodelu intenziteta i čine prelaze između tkiva uočljivijim. Najpoznatija je adaptivno izjednačavanje histograma sa ograničenjem kontrasta (engl. Contrast Limited Adaptive Histogram Equalization, CLAHE), koja sliku deli na manje regione i u svakom posebno prilagođava raspodelu intenziteta. Time se pojačavaju lokalne razlike, što kod tumora može olakšati uočavanje granice lezije.

I ovde važi pravilo da intervencija ne sme da bude prejaka. CLAHE primenjen sa preteranim parametrima može stvoriti veštačke teksture i pojačati šum, što kasnije zbunjuje mrežu. Predobrada je korisna onoliko koliko poboljšava kvalitet signala bez unošenja novih izobličenja.

5. DATA AUGMENTACIJA

Skup MRI snimaka za klasifikaciju tumora retko je dovoljno velik. Anotiranje zahteva stručnjaka, broj pacijenata sa određenim tipom tumora je ograničen, a etička i pravna pitanja dodatno usporavaju razmenu podataka između ustanova. U takvim uslovima jedan od najefikasnijih načina da se mreži obezbedi više raznolikosti u trening skupu je veštačko proširivanje postojećih slika kroz transformacije, postupak poznat kao augmentacija podataka (engl. data augmentation).

5.1 Logika augmentacije i njena uloga

Osnovna ideja augmentacije je jednostavna. Ako mreža treba da nauči da prepozna tumor bez obzira na to kako je snimak orijentisan, koliko je svetao ili koliko je tačno centriran, onda joj treba pokazati primere koji odražavaju tu varijabilnost. Umesto da se čeka da takvi primeri prirodno postoje u skupu, oni se generišu transformacijama postojećih slika.

Augmentacija ne dodaje novu informaciju u striktnom smislu reči. Iz jedne slike ne nastaje druga, nezavisna slika, već varijanta koja zadrži istu klasu, ali se nekim parametrom razlikuje od originala. Korist se ipak meri u praksi: mreža izložena većem broju varijanti istog primera teže nauči nebitne karakteristike i bolje generalizuje na nove snimke.

U medicinskom kontekstu augmentacija ima i specifičnu ulogu koja prevazilazi puko proširivanje skupa. Pošto su realni MRI snimci nastali pod različitim uslovima, kontrolisana augmentacija omogućava da se ta varijabilnost simulira već u fazi obuke. Mreža tako vidi raznolikost koja je slična onoj sa kojom će se susresti u produkciji, što direktno utiče na njenu robusnost.

5.2 Geometrijske transformacije

Najčešća grupa augmentacija obuhvata geometrijske transformacije. Tu spadaju rotacija, horizontalni i vertikalni preklap (engl. flip), pomeranje (engl. translation), skaliranje i nasumično izrezivanje delova slike. Svaka od ovih transformacija menja položaj sadržaja na slici, ali ne menja sam sadržaj.

Kod MRI snimaka mozga geometrijske transformacije moraju biti pažljivo birane. Mozak ima približnu bilateralnu simetriju, pa je horizontalni flip u većini slučajeva prihvatljiv, jer ne stvara anatomske besmislene slike. Vertikalni flip je drugačija priča. Snimak okrenut naopako više ne odgovara realnoj orijentaciji koju mreža treba da prepozna. U najboljem slučaju takav primer ne donosi korist, a u gorem unosi šum koji konfunduje mrežu.

Slično važi i za rotaciju. Manji uglovi, do desetak stepeni, mogu simulirati prirodne razlike u pozicioniranju glave tokom snimanja. Velike rotacije, na primer od 90 ili 180 stepeni, daju slike koje se u praksi nikada ne sreću, pa njihovo uključivanje obučava mrežu na situacije koje se neće dogoditi. Pomeranje i blago skaliranje su uglavnom bezbedni, sve dok se vodi računa da oblast od interesa ostane unutar slike.

5.3 Fotometrijske transformacije

Druga važna grupa augmentacija deluje na intenzitet, a ne na geometriju. Tu spadaju promene osvetljenja, kontrasta, dodavanje veštačkog šuma i blago zamućenje. Cilj je simulirati varijabilnost koja prirodno nastaje između uređaja i protokola, i naučiti mrežu da bude otporna na takve razlike.

Kod opštih slika često se koriste i promene boje (engl. color jitter), kojima se menjaju parametri zasićenja, nijanse i sličnih karakteristika. Kod MRI snimaka, koji su uglavnom sivih tonova, pojam boje nema istu ulogu. Ono što ostaje smisleno je promena srednjeg intenziteta i raspona kontrasta, jer takva intervencija odražava razlike koje se zaista sreću među realnim snimcima.

Veštačko dodavanje šuma može delovati kontraintuitivno, ali ima svoju logiku. Ako mreža tokom obuke vidi i čiste i blago zašumljene verzije iste slike, manje će se osloniti na fine detalje koji mogu biti tehnički artefakt, a više na strukturu koja se zadržava. Slično važi i za blago zamućenje. Ono primorava mrežu da nauči obrasce koji su dovoljno robusni da se prepoznaju i kada slika nije idealne oštine.

5.4 Napredne tehnike augmentacije

Pored klasičnih transformacija, u literaturi se javlja i niz naprednijih tehnika. Među njima su elastične deformacije, koje sliku lokalno izobličavaju kao da je istegnuta po nepravilnom obrascu. Kod prirodnih slika ova tehnika može delovati grubo, ali kod medicinskih je bliska realnoj varijabilnosti, jer ljudska anatomija jeste donekle elastična, pa različiti pacijenti imaju blago različite oblike istih struktura.

Druga grupa naprednijih pristupa kombinuje više slika. Tehnika MixUp uzima dve slike iz skupa i pravi novu sliku kao njihov ponderisani prosek, pri čemu se i klasna oznaka kombinuje proporcionalno. Tehnika CutMix umesto prosečenja izrezuje deo jedne slike i lepi ga na drugu. Obe tehnike mreži otežavaju da se previše veže za pojedinačne primere i mogu poboljšati generalizaciju.

Primena ovih naprednih tehnika u medicini zahteva oprez. MixUp između dve klase tumora stvara sliku koja anatomske nije realna i čija je oznaka neodređena. U nekim radovima takvi pristupi ipak daju dobre rezultate, ali ih treba uvoditi pažljivo i uz proveru kako se ponašaju na konkretnom skupu.

5.5 Granice augmentacije

Augmentacija nije čarobni štapić. Postoji granica posle koje dodatne transformacije ne donose dodatnu korist, a mogu i da škode. Ako se primenjuje preagresivno, mreža može da se obučava na slikama koje više ne odgovaraju realnoj raspodeli, što na kraju vodi ka modelu koji dobro radi na augmentovanim primerima, a slabije na originalnim test snimcima.

Drugi problem je što augmentacija ne rešava nedostatak strukturne raznolikosti u skupu. Ako su svi snimci u trening skupu napravljeni na istom uređaju, nikakva rotacija ili promena kontrasta neće naučiti mrežu kako izgleda snimak iz druge ustanove. Augmentacija proširuje varijabilnost unutar postojećih primera, ali ne stvara potpuno nove obrasce.

Otuda izbor augmentacija ne treba shvatiti kao listu transformacija koje se uvek primenjuju, već kao odluku koja zavisi od skupa, zadatka i ponašanja modela. Dobro postavljena augmentacija odražava varijabilnost koja se očekuje u stvarnoj primeni, dok loše postavljena unosi šum ili obučava mrežu za scenarije koji se ne dešavaju.

6. SPECIFIČNOSTI PREDOBRADE MEDICINSKIH SLIKA

Do sada razmotrene tehnike predobrade i augmentacije važe, sa manjim prilagođavanjima, i za opšte zadatke računarske vizije. Medicinske slike, međutim, imaju niz specifičnosti koje zahtevaju dodatne korake. Ovo poglavlje razmatra one delove predobrade koji se posebno javljaju u radu sa MRI snimcima i koji nemaju direktan pandan u opštoj klasifikaciji slika.

6.1 Skull stripping i izrezivanje regiona od interesa

Snimak mozga snimljen MRI uređajem ne sadrži samo moždano tkivo. Na slici su, pored mozga, vidljivi i lobanja, koža, mišići, masno tkivo i u nekim slučajevima delovi vrata. Iz dijagnostičke perspektive sve to je nepotreban kontekst jer se tumor traži unutar mozga, a ne u okolnim strukturama.

Postupak kojim se sa slike uklanja sve što nije moždano tkivo poznat je kao odstranjivanje lobanje (engl. skull stripping). Tehnika se sprovodi nizom algoritama, od jednostavnih pragova intenziteta do sofisticiranih segmentacionih mreža, a cilj je dobiti masku koja označava samo regione od interesa. Svaki piksel van te maske se postavlja na vrednost pozadine, najčešće nulu, ili se izrezuje zajedno sa pripadajućim okvirom slike.

Korist od ovog postupka je dvostruka. Prvo, mreža se ne mora obučavati da ignoriše strukture koje nisu relevantne za zadatak, što oslobađa kapacitet za učenje pravih obrazaca. Drugo, smanjuje se rizik da model nauči nešto što tehnički korelira sa klasom, ali nije medicinski relevantno. Različite ustanove imaju različite protokole za pozicioniranje pacijenta, pa lobanja na snimcima iz dve bolnice može izgledati različito iako je tkivo unutar mozga isto.

Postupak ipak nije bez rizika. Loše izvedeno odstranjivanje lobanje može slučajno ukloniti deo moždanog tkiva blizu površine, što kod tumora koji se javljaju u tom regionu može biti problematično. Otuda izbor metode i njena kalibracija zaslužuju pažnju, posebno kada je skup heterogen i potiče iz više izvora.

6.2 Bias field korekcija

Jedan od specifičnih artefakata MRI snimaka je nehomogenost intenziteta poznata kao bias field. Reč je o sporo promenljivom odklonu intenziteta preko slike, koji nastaje zbog nesavršenosti magnetnog polja i karakteristika same opreme. Posledica je da isti tip tkiva može imati приметно različit intenzitet u različitim delovima slike, čak i kada anatomske ne postoji nikakva razlika.

Ovaj artefakt nije slučajni šum, već strukturna pojava koja prati prostornu raspodelu signala. Mreža koja se obučava na slikama sa izraženim bias field-om može slučajno da nauči obrazac koji prati tu nehomogenost umesto stvarnih obrazaca tkiva. Posledica je smanjena generalizacija, jer se na novim snimcima bias field može pojaviti u drugačijem obliku.

Korekcija bias field-a izvodi se algoritmima koji procenjuju spori tok intenziteta preko slike i potom oduzimaju procenjenju komponentu od originalnog signala. Najpoznatiji među njima je N4 algoritam koji iterativno procenjuje glatku površinu koja najbolje opisuje neuniformnost. Posle korekcije, slika ima ujednačenu raspodelu intenziteta unutar istog tkiva, što olakšava i kasniju normalizaciju i samu klasifikaciju.

Treba napomenuti da bias field korekcija nije uvek neophodna. Kod modernih uređaja sa dobrom kalibracijom artefakt može biti dovoljno blag da ne utiče bitno na performanse. Otuda i ovaj korak treba uključiti tek pošto se utvrdi da je problem zaista prisutan u datom skupu.

6.3 Registracija i prostorna usklađenost

Kod skupova koji obuhvataju snimke više pacijenata postavlja se pitanje prostorne usklađenosti. Mozak svake osobe ima blago drugačiju veličinu, oblik i orijentaciju na snimku. Ako mreža treba da pronađe tumor na osnovu njegovog položaja, varijacije u tome kako su pacijenti pozicionirani mogu otežati učenje.

Postupak kojim se snimci dovode u zajednički prostorni okvir poznat je kao registracija. Ideja je da se svi snimci poravnaju u odnosu na referentni atlas, tako da iste anatomske strukture leže na istim koordinatama. Registracija može biti jednostavna, kada se vrši samo translacija i rotacija, ili složena, sa elastičnim deformacijama koje uklapaju i pojedinačne razlike u veličini struktura.

Korist od registracije najveća je kod zadataka koji se oslanjaju na lokalizaciju, gde je važno gde se promena nalazi, a ne samo postoji li. Kod čiste klasifikacije, gde se traži samo tip tumora, registracija ima manji uticaj, ali može doprineti smanjenju varijabilnosti u skupu.

Ovaj korak je tehnički zahtevan i vremenski skup, pa se u praksi često izostavlja kod jednostavnijih klasifikacionih zadataka. Kada se koristi, postaje deo lanca predobrade koji se mora dosledno primenjivati i na trening i na test slike.

6.4 Strategije za rad sa malim skupovima

Konačno, vredi izdvojiti smernice koje su specifične za rad sa malim medicinskim skupovima, jer su one česta realnost u istraživanjima koja se oslanjaju na javno dostupne podatke. Mali skup ne znači samo da modeli teže generalizuju, već i da svaki primer ima srazmerno veću težinu, pa kvalitet predobrade postaje proporcionalno važniji.

Prva strategija je pažljivo razdvajanje podataka. Slike koje potiču od istog pacijenta moraju ići u istu particiju, bilo trening, bilo test, jer u suprotnom evaluacija precenjuje stvarne performanse modela. Drugi važan korak je stratifikovana podela, koja čuva proporciju klasa u svakoj particiji, naročito kad je skup nebalansiran.

Druga strategija je konzervativna augmentacija. Kod malih skupova postoji iskušenje da se augmentacijom veštački poveća broj primera do velikih razmera, ali to često ne donosi očekivanu korist. Mreža u takvom režimu može da nauči i obrasce specifične za samu augmentaciju, umesto za stvarne klase. Otuda je pametnije primeniti umerenu augmentaciju i kombinovati je sa pristupom transfer learning-a.

Treća strategija je oslanjanje na predtrenirane mreže. Umesto obuke od nule, koristi se mreža čiji su niži slojevi već naučeni na velikom skupu opštih slika, a samo gornji

slojevi se prilagođavaju medicinskim podacima. Predobrada za ovaj pristup mora biti dosledna sa onom koju je predtrenirana mreža očekivala, što direktno povezuje izbor predobrade sa izborom mreže.

Konačno, evaluacija na malim skupovima zahteva pažljiviju metodologiju. Unakrsna validacija (engl. cross-validation) sa više preklopa daje stabilniju procenu performansi nego jedna podela, jer smanjuje uticaj slučaja prilikom izbora trening i test skupa. Bez ovog koraka, prijavljeni rezultati mogu zavisiti više od izbora podele nego od stvarne sposobnosti modela.

7. CNN ARHITEKTURE I OSETLJIVOST NA PREDOBRADU

Do sada je razmatrano šta sve može da se uradi sa slikom pre nego što stigne do mreže. Ostalo je pitanje šta se sa njom dešava unutar mreže i zašto predobrada uopšte ima toliki uticaj. Konvolucione mreže imaju specifičan način posmatranja ulaza, koji direktno određuje zašto neke transformacije pomažu, a druge ne.

7.1 Šta CNN “vidi” i zašto je predobrada bitna

Konvoluciona mreža ne posmatra sliku kao celinu, već je obrađuje kroz niz lokalnih operacija. Mali filteri klize preko slike i u svakom regionu računaju ponderisani prosek piksela, pri čemu se isti filter primenjuje na sve delove slike. Ovaj postupak se ponavlja kroz više slojeva, gde svaki sledeći sloj radi nad izlazima prethodnog, pa mreža postepeno prelazi sa najjednostavnijih obrazaca, poput ivica i tekstura, ka složenijim strukturama.

Posledica takve arhitekture je da mreža uči obrasce koji su lokalno definisani i u velikoj meri zavise od konkretnih vrednosti intenziteta na ulazu. Ako se isti tumor na dve slike pojavljuje sa različitim opsegom intenziteta, jer su slike snimljene na različitim aparatima, mreža ne vidi “isti tumor pod različitim uslovima”. Ona vidi dve različite raspodele brojeva, i ako joj predobrada ne omogući da te razlike prepozna kao nebitne, mora da nauči da ih sama kompenzuje.

Tu se vidi zašto je predobrada toliko važna. Mreža će, ako mora, naučiti da ignoriše sistematske razlike između uređaja, ali to traži deo kapaciteta i deo trening podataka. Predobrada koja te razlike ukloni unapred oslobađa mrežu da se fokusira na ono što je dijagnostički relevantno, a ne na razlike u tehničkim uslovima snimanja.

7.2 Transfer learning i sukob distribucija

Kod malih medicinskih skupova retko se mreža obučava od nule. Mnogo češće se koristi pristup poznat kao učenje prenošenjem (engl. transfer learning), gde se kreće od mreže koja je već obučena na velikom skupu opštih slika, najčešće ImageNet, a zatim se ona dodatno obučava na medicinskim podacima. Logika je da niži slojevi mreže već znaju da prepoznaju ivice, teksture i jednostavne obrasce, koji su korisni i za medicinske slike, pa nema potrebe da se to ponovo uči.

Pristup je u praksi vrlo uspešan, ali ima jednu suptilnu posledicu. Predtrenirana mreža očekuje ulaz koji izgleda slično onome na čemu je obučena. ImageNet slike su slike u boji, sa karakterističnom raspodelom intenziteta i statistikom koja se značajno razlikuje od MRI snimaka. Ako se MRI slika ubaci u takvu mrežu bez prilagođavanja, niži slojevi će ipak raditi nešto, ali ne ono što je optimalno za medicinski kontekst.

Otuda predobrada za transfer learning često uključuje korake koji nisu očigledni iz čisto medicinske perspektive. Slika sivih tonova se kopira u tri kanala da bi imitirala format slike u boji, intenzitet se skalira tako da odgovara raspodeli koju mreža očekuje, i dimenzije se prilagođavaju ulaznom sloju predtrenirane arhitekture. Svaki od ovih koraka ima cenu i korist, i izbor zavisi od konkretne mreže koja se koristi.

7.3 Batch normalization i njen odnos sa ulaznom normalizacijom

Većina savremenih CNN arhitektura unutar sebe koristi sloj poznat kao normalizacija po grupi (engl. batch normalization). Ovaj sloj tokom obuke ujednačava statistiku aktivacija unutar mreže, oduzimajući srednju vrednost i deleći standardnom devijacijom, slično kao što se radi i sa ulazom. Cilj je da se aktivacije kroz mrežu ne razlikuju previše po skali, što ubrzava i stabilizuje obuku.

Postavlja se prirodno pitanje da li je u tom slučaju ulazna normalizacija uopšte potrebna, kada mreža već normalizuje aktivacije unutar sebe. Odgovor je da jeste. Batch normalization radi nad već formiranim aktivacijama, dakle nad onim što su raniji slojevi izračunali. Ako je ulaz loše skaliran, prvi sloj već radi sa nestabilnim brojevima, a kasniji slojevi mogu samo delimično da to kompenzuju. Pored toga, u režimu inferencije, kada se mreža primenjuje na nove slike, koriste se fiksne vrednosti naučene tokom obuke, pa neusklađen ulaz može direktno da pokvari ponašanje modela.

Ulazna normalizacija i batch normalization stoga rade zajedno, ali na različitim nivoima. Prva osigurava da slika koja ulazi u mrežu ima predvidljivu statistiku, druga osigurava da se ta statistika održava i kroz kasnije slojeve. Izostavljanje bilo koje od te dve sigurnosne mreže obično vodi ka manje stabilnoj obuci.

7.4 Osetljivost arhitekture na ulazne uslove

Različite CNN arhitekture nisu jednako osetljive na predobradu. Plitke mreže sa malim brojem slojeva imaju ograničen kapacitet da se nose sa lošim ulazom, pa svaka slabost u predobradi direktno utiče na performanse. Duboke mreže, sa desetinama ili stotinama slojeva, imaju veću sposobnost da nauče da kompenzuju nepravilnosti, ali to plaćaju kroz potrebu za više podataka i duže vreme obuke.

Kod malih medicinskih skupova ovaj odnos postaje važan. Ako skup nije velik, dublja mreža ne može da realizuje svoj potencijal, jer joj nedostaje raznolikost primera potrebnih da nauči dobru reprezentaciju. U takvim uslovima dobra predobrada može imati veći uticaj nego izbor između dve slične arhitekture.

Otuda izbor predobrade i izbor arhitekture nisu nezavisne odluke. Plitke mreže traže pažljiviju predobradu, dublje mreže su tolerantnije, ali ni jedne ni druge ne mogu da rade dobro sa ulazom koji je sistematski neuređan. Najbolji rezultati se obično dobijaju kada se obe odluke donose zajedno, sa istim razumevanjem prirode skupa i zadatka.

8. UTICAJ PREDOBRADE NA PERFORMANSE KLASIFIKACIJE

Posle svega što je do sada izneto, ostaje konačno pitanje. Kakva je veza između izbora predobrade i stvarnih performansi modela za klasifikaciju tumora? Odgovor nije jednoznačan, jer performanse zavise od više činilaca koji deluju istovremeno, ali nekoliko tendencija se može jasno izdvojiti.

8.1 Generalizacija i overfitting na malim skupovima

Mali skupovi MRI snimaka stvaraju idealne uslove za pojavu poznatu kao prenaučenosť (engl. overfitting). Mreža sa dovoljno kapaciteta može da nauči tačno onaj trening skup koji je dobila, uključujući i sve njegove specifičnosti, ali da pri tome ne nauči ono što je zaista karakteristično za bolest. Posledica je odličan rezultat na trening podacima i znatno slabiji rezultat na novim slikama.

Predobrada utiče na ovaj problem na dva načina. Prvo, čišćenje skupa i normalizacija intenziteta uklanjaju sistematske razlike koje mreža inače može da iskoristi kao prečicu. Ako su sve slike jedne klase tehnički sličnije nego slike iz različitih klasa, mreža će prvo pokušati da nauči tu tehničku razliku, jer je to lakši put nego učenje stvarnih anatomskih obrazaca. Predobrada koja ujednači tehničku stranu primorava mrežu da posegne za pravim signalom.

Drugo, augmentacija direktno suzbija prenaučenosť. Ako mreža u svakoj epohi vidi malo drugačiju verziju iste slike, teže pamti pojedinačne primere i lakše uči obrasce koji se zadržavaju kroz transformacije. Efekat je posebno jak kod malih skupova, gde svaka dodatna varijacija nosi srazmerno veću informacionu vrednost.

Treba reći i da postoji granica iza koje predobrada više ne pomaže generalizaciji. Ako se ulaz toliko izmeni da više ne odražava ono što mreža treba da prepozna u stvarnoj primeni, model dobro radi tokom obuke, a slabije u produkciji. Otuda važi pravilo da predobrada treba da odražava varijabilnost koja se realno očekuje, ne da je veštački nadmaši.

8.2 Nebalansiranost klasa

Kod klasifikacije tumora retko su sve klase jednako zastupljene. U javnim skupovima, kao što je i Brain Tumor MRI Dataset koji se koristi u praktičnom delu, pojedine klase imaju značajno manje primera od ostalih. Mreža obučena na takvom skupu ima prirodnu tendenciju da favorizuje brojnije klase, jer ih češće viđa tokom obuke i jer je predviđanje brojnije klase statistički sigurnija strategija.

Predobrada se sa ovim problemom suočava na više načina. Augmentacija se može primeniti selektivno, tako da se manjinske klase veštački povećaju kroz transformacije, dok se brojnije klase ostavljaju kakve jesu. Time se broj primera po klasi približava bez prikupljanja novih podataka. Drugi pristup je vezan za sam izbor metrike: umesto da se model ocenjuje samo po ukupnoj tačnosti, koja može biti zavarana brojem ispravnih predikcija u dominantnoj klasi, koriste se metrike koje uzimaju u obzir performanse po svakoj klasi posebno.

Treba imati u vidu da nijedna od ovih intervencija ne menja činjenicu da skup ima više primera jedne nego druge klase. Predobrada može da ublaži posledicu, ali ne i uzrok. Pravo rešenje je uvek prikupljanje više podataka iz manjinskih klasa, kada je to moguće.

8.3 Stabilnost obuke i konvergencija

Predobrada ne utiče samo na konačnu tačnost, već i na sam proces obuke. Slabo skalirani ulaz, ili ulaz sa velikim razlikama u statistici između primera, može da uspori konvergenciju i učini je manje stabilnom. Mreža u takvim uslovima provodi prve epohe tražeći približnu skalu pre nego što počne da uči stvarne obrasce.

Normalizovan i ujednačen ulaz omogućava bržu i stabilniju obuku. Gradijenti se kreću u predvidljivim opsezima, optimizator lakše bira veličinu koraka, a verovatnoća da obuka divergira ili zapne u lokalnom minimumu opada. Ovaj efekat je posebno vidljiv u prvim epohama, kada nestabilni ulaz može da napravi veliku razliku u tome gde mreža uopšte počinje da uči.

Sa druge strane, predobrada koja je previše agresivna može da ukloni i deo informacije koji bi mreži pomogao u učenju. Granica nije univerzalna i zavisi od konkretne arhitekture i skupa, ali pravac razmišljanja je isti. Cilj je dovoljno predobrade da se obuka stabilizuje, ali ne toliko da se izgubi razlika između klasa.

8.4 Pouzdanost u kliničkom kontekstu

Sve dosadašnje razmatranje ticalo se metrika koje se koriste u istraživačkom okruženju, poput tačnosti i F1-mere. Klinička primena postavlja dodatne zahteve koji se ne svode samo na te brojeve. Model koji u istraživanju ima tačnost od 95 odsto i dalje može biti neprihvatljiv u praksi ako preostalih 5 odsto greški pogađa upravo najteže slučajeve, ili ako je nestabilan kada se primeni na snimke iz druge bolnice.

Predobrada ovde ima specifičnu ulogu. Doslednost predobrade između trening i produkcionog okruženja postaje kritična. Ako je model obučen na slikama koje su prošle određenu normalizaciju, isti taj postupak mora da se primeni i na svaku novu sliku koja se mreži šalje. Razlike u predobradi između faza dovode do pada performansi koji nije posledica modela, već nesklada u ulazu.

Pored toga, predobrada koja je dobro pripremljena olakšava interpretaciju modela. Ako se mreža vidno oslanja na karakteristike slike koje su tehničke prirode, na primer

na razliku u kontrastu između snimaka iz dve ustanove, to je signal da je predobrada nedovoljno ujednačila ulaz. Klinički pouzdan model treba da donosi odluke na osnovu anatomskih obrazaca, a ne tehničkih specifičnosti, i predobrada je primarni alat kojim se to obezbeđuje.

8.5 Sažeti pogled na vezu predobrade i performansi

Ako bi se sve dosadašnje moralo svesti na jednu rečenicu, ona bi glasila ovako. Predobrada nije sporedan korak, već deo modela u širem smislu reči, koji direktno oblikuje šta će mreža uopšte moći da nauči. Loša predobrada može da poništi prednosti najbolje arhitekture, dok dobra predobrada može omogućiti i jednostavnijoj mreži da postigne kliničku pouzdanost.

Otuda izbor predobrade ne treba shvatiti kao tehničku rutinu koja prethodi “pravom” radu, već kao odluku koja se donosi sa istom pažnjom kao i izbor algoritma. Praktični deo ovog rada, koji sledi u narednoj fazi, upravo i ima cilj da na konkretnom skupu MRI snimaka pokaže kako različite kombinacije predobrade i augmentacije utiču na performanse modela za klasifikaciju tumora mozga.

9. PREPORUKE I SMERNICE

Na osnovu razmotrene literature i prirode samih MRI snimaka mogu se izdvojiti smernice koje su korisne i za teorijski i za budući praktični deo rada. Nijedna od njih nije univerzalno pravilo, već skup polazišta koja olakšavaju donošenje konkretnih odluka u radu sa medicinskim skupovima slika.

9.1 Krenuti od kvaliteta ulaza, a ne od arhitekture

Prva smernica je metodološka. Pre nego što se uopšte razmišlja o tome koju CNN arhitekturu koristiti, treba razumeti kakvog su kvaliteta sami snimci. Ako su podaci opterećeni šumom, nedoslednom akvizicijom i velikim brojem varijanti istog tipa snimka, problem nije u prvom redu klasifikacioni već problem kvaliteta podataka.

Praksa pokazuje da značajan deo poboljšanja u medicinskoj klasifikaciji dolazi upravo iz pažljivo postavljene predobrade, a ne iz prelaska sa jedne arhitekture na drugu. Mreža koja radi sa kvalitetnim, ujednačenim ulazom često postiže bolje rezultate od složenije mreže koja radi sa neurednim podacima. Otuda prvi korak u svakom novom zadatku treba da bude analiza skupa, a ne izbor algoritma.

To ne znači da su arhitekture nevažne, već da njihov uticaj postaje vidljiv tek kada se podaci dovedu u stanje koje im omogućava da naprave razliku. Prevremeno traženje najbolje mreže pre nego što se reši problem ulaza često je gubljenje vremena.

9.2 Birati augmentaciju prema vrsti varijabilnosti

Druga smernica tiče se izbora augmentacije. Augmentacija nije lista transformacija koje se uvek primenjuju, već odluka koja zavisi od vrste varijabilnosti koja se očekuje u stvarnoj primeni. Kod jednog skupa ključna je razlika u orijentaciji

glave pacijenta, kod drugog razlika u kontrastu između uređaja, kod trećeg razlika u rezoluciji.

Otuda izbor augmentacija treba da prati dijagnozu skupa. Ako su slike nastale na više uređaja sa različitim parametrima, fotometrijske transformacije postaju važnije od geometrijskih. Ako su pacijenti različito pozicionirani, blage rotacije i pomeranja imaju veći smisao. Ako je skup mali, augmentacija u celini dobija veću ulogu, ali se mora primeniti pažljivo da ne unese nove obrasce koji ne odražavaju stvarnost.

Pravilo da treba simulirati onu varijabilnost koja se očekuje u produkciji vredi i za naprednije tehnike. MixUp i CutMix mogu biti korisni, ali njihova primena u medicini zahteva oprez i proveru, jer mogu stvoriti slike koje anatomske nemaju smisla.

9.3 Porediti predobrade a ne samo arhitekture

Treća smernica vezana je za način na koji se vodi eksperiment. Kada se u praktičnom radu poredi više modela, čest pristup je da se menja samo arhitektura, a predobrada se zadržava ista. Takvo poređenje često ne daje pravu sliku, jer različite arhitekture mogu imati različite zahteve prema ulazu.

Pravičnije poređenje uključuje i poređenje samih predobrada, pri istoj arhitekturi i istoj proceduri evaluacije. Tek tada se vidi koliko određena transformacija doprinosi performansama, nezavisno od izbora modela. Idealno bi bilo testirati i kombinacije, gde se za svaku arhitekturu nezavisno bira optimalna predobrada, ali to brzo postaje skupo i u praksi se pravi kompromis.

Ono što se uvek mora ispoštovati jeste pravilo da se u jednom eksperimentu menja samo jedan element. Ako se istovremeno menjaju i predobrada, i arhitektura, i parametri obuke, teško je kasnije reći odakle dolazi razlika u rezultatima.

9.4 Predobradu ocenjivati preko posledice po model

Četvrta smernica je epistemološke prirode. Predobrada se ne ocenjuje po tome koliko slike izgledaju lepše ili urednije posle nje, već po tome kako se menja ponašanje modela koji uči na njoj. Slika koja čoveku izgleda jasnija nije nužno slika koja mreži pomaže više od originalne.

Otuda svaku predobradu treba evaluirati u sklopu cele procedure obuke i evaluacije. Tačnost, F1-mera i druge metrike na test skupu pokazuju da li je transformacija stvarno bila korisna, ili je samo proizvela utisak boljeg ulaza. Ovaj princip važi i za augmentaciju, i za normalizaciju, i za bilo koju drugu intervenciju nad slikom.

Praktična posledica je da se transformacije moraju vrednovati unutar korektne eksperimentalne procedure. Ako se parametri predobrade biraju na osnovu test skupa, deo informacije iz testa neprimetno se uvuče u obuku, i rezultat izgleda bolji nego što bi bio u stvarnoj primeni. Predobrada zato nije izolovan korak, već deo iste metodologije koja obuhvata i obuku i evaluaciju.

9.5 Voditi računa o doslednosti između faza

Konačno, peta smernica vezana je za doslednost. Predobrada koja se primenjuje tokom obuke mora se na isti način primeniti i na svaku novu sliku koja se modelu kasnije prosleđuje. Razlika između dve faze, makar i mala, može biti dovoljna da se performanse modela u praksi naglo pogoršaju.

Ovo je posebno važno kod medicinskih sistema, gde model obučen u istraživačkom okruženju kasnije može biti integrisan u klinički sistem. Ako su parametri normalizacije, veličina ulaza ili procedura izrezivanja regiona od interesa različiti u dva okruženja, model može da daje rezultate koji se značajno razlikuju od onih iz istraživanja, iako sam model nije promenjen.

Otuda predobrada treba da bude dokumentovana i fiksirana zajedno sa modelom. Idealno se i sama integriše u model kao prvi korak obrade, tako da se ne može slučajno preskočiti ili izmeniti. Kada to nije moguće, jasno definisan i automatizovan procesni lanac pruža sličnu garanciju.

10. ZAKLJUČAK

U ovom radu razmatran je uticaj kvaliteta i tehnika predobrade slika na performanse modela za klasifikaciju tumora mozga. Pokazano je da MRI snimci, iako se na prvi pogled mogu posmatrati kao obične digitalne slike, nose niz specifičnosti koje običan pristup računarskoj viziji ne hvata u dovoljnoj meri. Intenzitet piksela na MRI slici nema apsolutno značenje, varira između uređaja i protokola, a sam skup retko je dovoljno velik da modeli mogu lako da generalizuju.

Iz literature i razmatranja izdvojeni su glavni izvori poteškoća. Rezolucija, kontrast i osvetljenje variraju između snimaka i ustanova. Šum, zamućenje i artefakti akvizicije menjaju kvalitet pojedinačnih slika. Duplikati i bliske varijante komplikuju evaluaciju i mogu da preuveličaju stvarne performanse modela. Svi ovi problemi traže pažljivu pripremu pre nego što se uopšte krene sa obukom mreže.

Posebna pažnja posvećena je tehnikama predobrade. Promena veličine, izrezivanje, normalizacija intenziteta, filtriranje šuma i poboljšanje kontrasta nisu sporedni tehnički detalji, već odluke koje direktno menjaju ono što model uopšte vidi kao signal. Augmentacija je u radu razmotrena kao zaseban deo, jer kod malih medicinskih skupova ima ulogu koja prevazilazi puko proširivanje broja primera. Geometrijske i fotometrijske transformacije, pažljivo birane prema prirodi medicinskih slika, pomažu mreži da nauči obrasce koji se zadržavaju kroz realnu varijabilnost.

Razmotren je i odnos predobrade i samih CNN arhitektura. Konvolucione mreže obrađuju sliku kroz lokalne operacije i njihova osetljivost na ulazne uslove zavisi od dubine arhitekture i veličine skupa. Transfer learning, batch normalization i izbor

ulazne normalizacije zajedno oblikuju kako se predobrada uklapa u širi proces obuke, pa se ti elementi ne mogu razmatrati nezavisno jedan od drugog.

Glavni zaključak rada jeste da performanse modela za klasifikaciju tumora mozga zavise od veze između tri elementa: kvaliteta ulaznih MRI snimaka, izabrane predobrade i načina na koji se ta predobrada uklapa u arhitekturu mreže. Loša predobrada može da poništi prednosti i najsofisticiranije arhitekture, dok dobro pripremljen ulaz može omogućiti i jednostavnijem modelu da postigne kliničku pouzdanost.

U praktičnom delu rada, koji sledi u narednoj fazi, ova veza biće proverena na Brain Tumor MRI skupu sa četiri klase, kroz poređenje više varijanti predobrade i augmentacije i njihovog uticaja na performanse klasifikacionog modela.

11. LITERATURA

- [1] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [2] Szeliski, R. (2022). *Computer Vision: Algorithms and Applications* (2nd ed.). Springer.
- [3] Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). Pearson.
- [4] Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A. W. M., van Ginneken, B., & Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60-88.
- [5] Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of Big Data*, 6(1), 1-48.
- [6] Garcia, S., Luengo, J., & Herrera, F. (2015). *Data Preprocessing in Data Mining*. Springer.
- [7] Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning* (pp. 448-456). PMLR.
- [8] Shin, H.-C., Roth, H. R., Gao, M., Lu, L., Xu, Z., Nogues, I., Yao, J., Mollura, D., & Summers, R. M. (2016). Deep convolutional neural networks for computer-aided detection: CNN architectures, dataset characteristics and transfer learning. *IEEE Transactions on Medical Imaging*, 35(5), 1285-1298.
- [9] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems* (Vol. 25, pp. 1097-1105).
- [10] Pizer, S. M., Amburn, E. P., Austin, J. D., Cromartie, R., Geselowitz, A., Greer, T., ter Haar Romeny, B., Zimmerman, J. B., & Zuiderveld, K. (1987). Adaptive histogram equalization and its variations. *Computer Vision, Graphics, and Image Processing*, 39(3), 355-368.
- [11] Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- [12] Tan, P.-N., Steinbach, M., & Kumar, V. (2006). *Introduction to Data Mining*. Addison-Wesley.
- [13] Nickparvar, M. (2021). *Brain Tumor MRI Dataset* [Data set]. Kaggle. Preuzeto sa <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>